

Predicción de Attrition de Empleados

Dataset IBM HR Analytics Employee Attrition & Performance

Materia: Aprendizaje Artificial

Autor: Fernando Caceres

Universidad CAECE · Materia: Aprendizaje Artificial

Resumen ejecutivo

Se construyó y comparó un conjunto de modelos de clasificación para predecir si un empleado abandonará la compañía (*attrition*), siguiendo las cinco etapas de Setiawan et al. (2020) y las técnicas de pre-procesado vistas en la unidad. Se evaluaron siete algoritmos: Regresión Logística, Árbol de Decisión (C4.5), Naive Bayes, KNN, Random Forest, SVM y Red Neuronal (MLP), además de una regresión logística estadística con selección de variables por VIF y eliminación hacia atrás, como en el paper de referencia.

- **Mejor modelo: Regresión Logística**, con AUC = 0,817 en el conjunto de prueba (0,828 en validación cruzada), sensibilidad del 68 % y especificidad del 79 %. Es comparable al paper de referencia (73 % y 75 %) y tiene la ventaja de ser interpretable.
- **Factores clave de abandono:** horas extra (odds $\approx \times 7$), perfil junior (poca edad y trayectoria), baja satisfacción y mal balance vida-trabajo, ingreso bajo para el nivel, ausencia de stock options, viajes frecuentes, estado civil soltero y los roles Sales Representative, Laboratory Technician y Human Resources.
- **Valor práctico:** el 20 % de empleados con mayor riesgo según el modelo concentra el 61 % de las bajas reales, lo que permite focalizar las acciones de retención.

Web interactiva: <https://caece-aprendizaje-artificial-rrhh.netlify.app>

Repositorio: <https://github.com/fcaceres-create/caece-aprendizaje-artificial-u3-rrhh>

1. Introducción y objetivo

El *attrition*, o abandono del empleo, es la reducción del número de empleados de una compañía. Puede ser **voluntario**, cuando el empleado se va por decisión propia, o **involuntario** (jubilaciones, despidos, fallecimientos). El voluntario es una de las principales preocupaciones de las empresas por el costo de reclutar y capacitar reemplazos, la pérdida de conocimiento y el impacto en la moral y la cultura organizacional.

Las técnicas de Data Mining permiten construir modelos que predicen las bajas a partir de los datos de los empleados. El **objetivo** de este trabajo es (a) construir un modelo que estime la probabilidad de que cada empleado abandone la compañía y (b) identificar los factores que más influyen, para que RRHH pueda actuar de forma preventiva.

2. Metodología

Se siguen las cinco etapas propuestas por Setiawan et al. (2020): (1) recolección de datos y entendimiento del negocio, (2) pre-procesado, (3) análisis exploratorio (EDA), (4) selección y entrenamiento de modelos y (5) prueba y evaluación. El trabajo se implementó en Python (pandas, scikit-learn, statsmodels) en un notebook de Jupyter que acompaña este informe.

2.1 Datos

El dataset IBM HR Analytics es un conjunto ficticio creado por científicos de datos de IBM. Tiene **1.470 empleados y 35 variables**: demográficas (edad, género, estado civil), laborales (departamento, rol, nivel, salario, antigüedad, horas extra, viajes) y de encuestas (satisfacción con el ambiente, el trabajo y las relaciones, involucramiento, balance vida-trabajo, desempeño). La variable objetivo **Attrition** toma el valor Yes en 237 casos (**16,1 %**, similar al 15,7 % del paper). Las clases están desbalanceadas: un modelo que siempre prediga "No" tendría 84 % de exactitud sin ninguna utilidad. Por eso se priorizan la sensibilidad, la especificidad, el F1 y el AUC.

2.2 Pre-procesado

Tarea	Acción realizada
Limpieza	No hay valores perdidos ni duplicados. Se detectaron outliers con el criterio IQR (ingreso, antigüedad), pero se conservaron por ser valores plausibles y no errores de carga.
Selección de atributos	Se eliminaron las variables con un único valor (EmployeeCount, Over18, StandardHours) y el identificador EmployeeNumber.
Derivación	Se crearon 5 atributos: IngresoPorNivel, AniosPromPorEmpresa, ProporcionAniosEnEmpresa, AniosSinPromocionRel y SatisfaccionTotal (promedio de 4 encuestas).
Discretización	Rango de edad (particionado manual), quintiles de ingreso (igual frecuencia) y etiquetas de las escalas ordinales. Solo se usaron para el EDA.
Codificación	Attrition a 0/1; one-hot encoding de las 7 variables nominales (49 atributos finales).
Normalización	Min-max a [0, 1], ajustada solo con el conjunto de entrenamiento (dentro de un pipeline).
Partición	70 % entrenamiento (1.029) / 30 % prueba (441), estratificada por Attrition.

3. Análisis exploratorio

La Figura 1 muestra la tasa de attrition por categoría; la línea punteada marca la tasa general (16,1 %) y en rojo se destacan las categorías que la superan.



Figura 1. Tasa de attrition por categoría (variables nominales ordenadas por tasa; ordinales en su orden natural).

Categoría	Empleados	Tasa de attrition
JobRole = Sales Representative	83	39,8 %
Edad 18–25	123	35,8 %
JobInvolvement = Bajo	83	33,7 %
Ingreso en el quintil más bajo	294	31,3 %
WorkLifeBalance = Malo	80	31,2 %
OverTime = Yes	416	30,5 %
JobLevel = 1	543	26,3 %
MaritalStatus = Single	470	25,5 %
EnvironmentSatisfaction = Bajo	284	25,4 %
BusinessTravel = Travel_Frequently	277	24,9 %




Figura 2. Distribución de variables numéricas según Attrition (0 = se queda, 1 = se va).

Quienes se van son más jóvenes (mediana de 32 contra 36 años), ganan menos (USD 3.202 contra 5.204 de ingreso mensual mediano), tienen menos experiencia total (7 contra 10 años) y menos antigüedad en la empresa (3 contra 6 años). Es decir, predomina un perfil **junior**, lo que coincide con el paper. La matriz de correlación (en el notebook) muestra fuertes correlaciones entre JobLevel, MonthlyIncome y TotalWorkingYears, y entre las variables de antigüedad: hay **multicolinealidad**, que se controló con VIF.

4. Selección y entrenamiento de modelos

4.1 Regresión logística estadística (enfoque del paper)

Se replicó el procedimiento de Setiawan et al. Primero se eliminaron iterativamente las variables con **VIF > 5**: EnvironmentSatisfaction (colinealidad perfecta con SatisfaccionTotal), MonthlyIncome, Department_Sales, EducationField_Life Sciences, Department_R&D, YearsAtCompany, TotalWorkingYears y JobLevel, con lo que quedaron 41 variables. Luego se aplicó **eliminación hacia atrás** quitando en cada paso la variable de mayor p-valor ($> 0,05$). Tras 25 modelos se llegó a uno final de **17 variables significativas** (AIC = 623,8; pseudo $R^2 = 0,354$).

Variable	Coeficiente	p-valor	Odds ratio	Efecto
YearsSinceLastPromotion	3,183	< 0,001	24,12	↑ riesgo
JobRole_Sales Representative	1,998	< 0,001	7,38	↑ riesgo
OverTime_Yes	1,968	< 0,001	7,16	↑ riesgo
BusinessTravel_Travel_Frequently	1,818	< 0,001	6,16	↑ riesgo
JobRole_Human Resources	1,779	< 0,001	5,93	↑ riesgo
JobRole_Laboratory Technician	1,417	< 0,001	4,13	↑ riesgo

Variable	Coeficiente	p-valor	Odds ratio	Efecto
DistanceFromHome	1,323	< 0,001	3,76	↑ riesgo
JobRole_Sales Executive	1,248	< 0,001	3,48	↑ riesgo
BusinessTravel_Travel_Rarely	0,886	0,047	2,42	↑ riesgo
MaritalStatus_Single	0,873	0,003	2,40	↑ riesgo
StockOptionLevel	-1,198	0,029	0,30	↓ riesgo
ProporcionAniosEnEmpresa	-1,290	0,005	0,28	↓ riesgo
WorkLifeBalance	-1,337	0,002	0,26	↓ riesgo
IngresoPorNivel	-1,436	0,019	0,24	↓ riesgo
Age	-2,094	0,001	0,12	↓ riesgo
SatisfaccionTotal	-4,268	< 0,001	0,01	↓ riesgo
AniosPromPorEmpresa	-11,160	< 0,001	< 0,001	↓ riesgo

Como las variables están normalizadas a [0, 1], el odds ratio compara el valor mínimo con el máximo de cada variable. Por ejemplo, hacer horas extra multiplica aproximadamente por 7 las chances de irse, mientras que una mayor satisfacción, más edad y más años promedio por empresa las reducen fuertemente.

4.2 Comparación de algoritmos

Se entrenaron siete algoritmos con búsqueda de hiperparámetros por grilla y **validación cruzada estratificada de 5 particiones** sobre el conjunto de entrenamiento, optimizando el AUC-ROC. Para compensar el desbalance se usó *class_weight = balanced* en Regresión Logística, Árbol, Random Forest y SVM.

Modelo	AUC CV (media ± desvío)	Mejores hiperparámetros
Red Neuronal (MLP)	0,836 ± 0,040	1 capa oculta de 8 neuronas, alpha = 1
Regresión Logística	0,828 ± 0,044	Penalización L1, C = 1
SVM	0,825 ± 0,044	Kernel lineal, C = 0,5
Random Forest	0,815 ± 0,038	500 árboles, profundidad máx. 10, max_features = sqrt
Naive Bayes	0,773 ± 0,040	Gaussiano, var_smoothing = 0,1
KNN	0,755 ± 0,057	k = 41, ponderado por distancia
Árbol de Decisión (C4.5)	0,727 ± 0,038	Entropía, profundidad 3, mín. 40 casos por hoja

5. Evaluación de los modelos

Los modelos se evaluaron sobre el 30 % de prueba (441 empleados, 71 bajas), que no se usó en el entrenamiento. La **sensibilidad** indica qué porcentaje de los que realmente se van detecta el modelo. La **especificidad** indica qué porcentaje de los que se quedan clasifica correctamente. El **AUC** mide la capacidad de ordenar a los empleados por riesgo, con independencia del umbral.

5.1 Resultados con umbral 0,5

Modelo	Accuracy	Sensib.	Especif.	Precisión	F1	AUC
Regresión Logística	77,3 %	67,6 %	79,2 %	38,4 %	0,490	0,817
Red Neuronal (MLP)	88,2 %	35,2 %	98,4 %	80,6 %	0,490	0,817
SVM	87,1 %	31,0 %	97,8 %	73,3 %	0,436	0,812
Logística estadística	77,6 %	70,4 %	78,9 %	39,1 %	0,503	0,796

Modelo	Accuracy	Sensib.	Especif.	Precisión	F1	AUC
Random Forest	81,0 %	45,1 %	87,8 %	41,6 %	0,432	0,750
KNN	84,1 %	1,4 %	100,0 %	100,0 %	0,028	0,742
Naive Bayes	74,1 %	62,0 %	76,5 %	33,6 %	0,436	0,737
Árbol de Decisión (C4.5)	73,2 %	43,7 %	78,9 %	28,4 %	0,344	0,695

Con el umbral estándar, la Red Neuronal, el SVM y KNN tienen alta exactitud pero **baja sensibilidad**: casi no predicen "se va" (KNN detecta 1 de 71). Por eso la exactitud no sirve como métrica principal en este problema. La Regresión Logística (umbral 0,5) y la logística estadística (umbral 0,16) sí equilibran ambas métricas.




Figura 3. Curvas ROC en el conjunto de prueba.

5.2 Resultados con umbral ajustado

El umbral de cada modelo se eligió con predicciones de validación cruzada sobre el entrenamiento, maximizando el índice de Youden (sensibilidad + especificidad – 1), y luego se aplicó al conjunto de prueba. Así, todos los algoritmos se comparan en igualdad de condiciones.

Modelo	Umbral	Accuracy	Sensib.	Especif.	F1	AUC
Regresión Logística	0,65	84,6 %	57,7 %	89,7 %	0,547	0,817
Red Neuronal (MLP)	0,24	84,1 %	62,0 %	88,4 %	0,557	0,817
SVM	0,22	81,9 %	64,8 %	85,1 %	0,535	0,812
Logística estadística	0,16	77,6 %	70,4 %	78,9 %	0,503	0,796
Random Forest	0,38	72,3 %	70,4 %	72,7 %	0,450	0,750
KNN	0,17	78,0 %	60,6 %	81,4 %	0,470	0,742
Naive Bayes	0,48	73,7 %	62,0 %	75,9 %	0,431	0,737
Árbol de Decisión (C4.5)	0,62	77,8 %	35,2 %	85,9 %	0,338	0,695




Figura 4. Comparación de métricas con umbral ajustado.




Figura 5. Matrices de confusión en el conjunto de prueba (umbral 0,5; 0,16 para la logística estadística).

5.3 Reglas del árbol de decisión

Como en el ejemplo con C4.5 del material de la unidad, un árbol de profundidad 3 permite extraer reglas fáciles de comunicar a RRHH. Las principales son:

- Si el empleado tiene **pocos años promedio por empresa** (trayectoria inestable) y es **joven**, se predice que se va.
- Si tiene pocos años promedio por empresa, es mayor, pero **hace horas extra**, se predice que se va.
- Si tiene una trayectoria estable, **hace horas extra** y su **satisfacción total es baja**, se predice que se va.
- Si tiene una trayectoria estable y no hace horas extra, se predice que se queda.




Figura 6. Árbol de decisión simplificado (profundidad 3; valores normalizados a [0, 1]).




Figura 7. Importancia de variables en Random Forest y coeficientes de la Regresión Logística.

5.4 Aplicación: ranking de riesgo

El uso práctico del modelo es ordenar a los empleados por probabilidad de irse. En el conjunto de prueba, el **20 % con mayor riesgo concentra el 61 % de las bajas reales**: su tasa de attrition es del 49 %, contra el 16 % general. Los primeros puestos del ranking corresponden mayoritariamente a Sales Representatives jóvenes, solteros, con horas extra, ingresos bajos y poca antigüedad.

6. Conclusiones

Métrica	Paper (Setiawan et al.)	Logística estadística	Logística regularizada (umbral 0,5)
Accuracy	75 %	78 %	77 %
Sensibilidad	73 %	70 %	68 %
Especificidad	75 %	79 %	79 %

- La **Regresión Logística** es el modelo recomendado: fue la mejor en prueba (AUC 0,817), es estable en validación cruzada y es interpretable. Coincide con lo reportado por Frye et al. (2018), citado en el paper. Los resultados son comparables al paper, aunque los datasets no son idénticos: el paper usa la versión de 4.410 empleados con registros de horario.

- Los modelos lineales y la red neuronal pequeña superaron a los basados en árboles y a KNN. Con pocos datos (166 bajas en entrenamiento) y relaciones mayormente monótonas, los modelos simples generalizan mejor. Naive Bayes se ve afectado porque las variables de antigüedad, edad e ingreso no son independientes.
- El **umbral de decisión** es una decisión de negocio tan relevante como el algoritmo. Bajarlo detecta más bajas a costa de más falsas alarmas, que suelen ser baratas (una entrevista de retención) comparadas con reemplazar a un empleado.

Recomendaciones para RRHH

- Controlar y redistribuir las **horas extra**, y revisar las cargas de trabajo en los roles críticos.
- Armar **planes de carrera y promoción** para empleados jóvenes y de nivel 1: mentoring y objetivos claros de ascenso.
- Revisar las **bandas salariales y los stock options** en los niveles bajos.
- Definir políticas de **viajes** y de trabajo flexible o remoto para quienes viven lejos.
- Hacer encuestas periódicas de **clima** y seguir de cerca a quienes reportan baja satisfacción.
- Usar el **ranking de riesgo** para priorizar entrevistas de retención.

Limitaciones y trabajo futuro

- El dataset es **ficticio** y chico (237 bajas): los resultados deben validarse con datos reales.
- Es una **foto estática**: no permite el esquema visto en clase de usar N meses de historia para predecir las bajas de los M meses siguientes. Con datos reales conviene construir variables dinámicas (evolución salarial, ausentismo, cambios de jefe) y reentrenar el modelo periódicamente.
- No distingue el attrition **voluntario** del **involuntario**.

Referencias

- Setiawan, I., Suprihanto, S., Nugraha, A. C. y Hutahaeen, J. (2020). HR analytics: Employee attrition analysis using logistic regression. *IOP Conf. Series: Materials Science and Engineering*, 830, 032001.
- Frye, A., Boomhower, C., Smith, M., Vitovsky, L. y Fabricant, S. (2018). Employee Attrition: What Makes an Employee Quit? *SMU Data Science Review*, 1(1).
- Azcurra, J. (2022). *Data Mining Empresarial – Unidad 3: Aplicaciones de Data Mining en RRHH*. Maestría en Ciencia de Datos e Innovación Empresarial.
- Minería de Datos en Educación y Análisis del Aprendizaje* (material de la unidad): pre-procesado de datos y técnicas de clasificación.
- IBM. *IBM HR Analytics Employee Attrition & Performance* [dataset]. Kaggle.
- Caceres, F. *Predicción de attrition de empleados: web interactiva*. Netlify.
<https://caece-aprendizaje-artificial-rrhh.netlify.app>
- Caceres, F. *Repositorio del proyecto: código, notebook y datos*. GitHub.
<https://github.com/fcaceres-create/caece-aprendizaje-artificial-u3-rrhh>